

Computación Cuántica

Universidad Nacional Autónoma de México - Facultad de Ciencias

Alumno. Sebastián González Juárez



- [1] Quantum Machine Learning. M Schuld, I Sinayskiy, and F Petruccione. Contemporary Physics (56/2), pp. 172-185 (2015)
- [2] Quantum Machine Learning. J Biamonte, P Wittek, N Pancotti, P Rebentrost, N Wiebe, and S Lloyd, Nature 549 pp. 195-202 (2017)

Lectura 8 (Yo presente el paper en clase)

El primer artículo presenta una introducción clara al campo del *quantum machine learning* (QML) para su respectivo año, cuyo objetivo principal es combinar herramientas de la computación cuántica con algoritmos de aprendizaje automático para mejorar su desempeño. Desde el inicio, el texto enfatiza que el machine learning consiste en encontrar patrones a partir de datos para interpretar información desconocida, destacando que el verdadero reto no es solo aprender, sino hacerlo de manera eficiente frente al crecimiento masivo de datos.

El artículo establece primero las bases del aprendizaje automático clásico, distinguiendo entre aprendizaje supervisado, no supervisado y por refuerzo. Sin embargo, el enfoque se centra en los dos primeros, ya que son los más relevantes para tareas como clasificación y clustering. Se resalta que, en estos métodos, el aprendizaje suele implicar la optimización de parámetros del modelo, lo cual puede ser computacionalmente costoso, especialmente en escenarios de big data.

A partir de esta problemática, se introduce la computación cuántica como una posible solución. La idea clave es que los sistemas cuánticos permiten representar y procesar información de manera distinta, utilizando superposición y paralelismo cuántico. No obstante, el artículo señala una dificultad fundamental: los datos clásicos deben codificarse en estados cuánticos, y esta representación no siempre preserva la estructura relevante de los datos, como las distancias entre vectores.

Posteriormente, el paper analiza distintas versiones cuánticas de algoritmos clásicos. En el caso de *k-nearest neighbors*, el problema central (calcular distancias) se transforma en medir similitud entre estados cuánticos mediante el *swap test*, lo que permite estimar productos internos a partir de probabilidades de medición. De forma similar, en máquinas de soporte vectorial, el cuello de botella asociado al cálculo del kernel se aborda mediante representaciones cuánticas que permiten evaluar productos internos de manera más eficiente.

En clustering, se propone reinterpretar las distancias como fidelidades entre estados cuánticos o incluso reformular el problema como uno de optimización mediante computación adiabática. Sin embargo, en modelos más complejos como redes neuronales o árboles de decisión, el artículo reconoce que aún no existen versiones cuánticas completas y eficientes, principalmente debido a la dificultad de introducir no linealidad en sistemas cuánticos.

En mi opinión, lo más importante de este paper es que deja claro que el QML tiene un campo en desarrollo. Aunque existen propuestas prometedoras, muchas se enfocan en acelerar subrutinas específicas más que en redefinir el proceso de aprendizaje. Esto sugiere que el verdadero avance no será simplemente "cuantizar" algoritmos clásicos, sino encontrar modelos de aprendizaje genuinamente cuánticos.

El segundo artículo amplía la perspectiva del primero al presentar un panorama más general de los avances en QML, con un enfoque particular en algoritmos basados en álgebra lineal y en el análisis de su complejidad. Desde el inicio, se plantea que el aprendizaje automático se ha vuelto una herramienta fundamental en la ciencia moderna, y que la computación cuántica podría permitir identificar patrones que serían inaccesibles para métodos clásicos en tiempos razonables.

Una contribución importante de este paper es su análisis crítico de las ventajas cuánticas. Se introducen conceptos como *query complexity* y *gate complexity*, que permiten evaluar teóricamente la eficiencia de los algoritmos

cuánticos. Sin embargo, también se advierte que estas métricas suelen ser idealizadas y no consideran limitaciones prácticas como el acceso a los datos o el costo de implementación.

El artículo describe varios algoritmos clave. Uno de los más importantes es el *quantum principal component analysis* (qPCA), que permite extraer las componentes principales de un conjunto de datos mediante la diagonalización de una matriz de densidad. Bajo ciertas condiciones, este algoritmo presenta una complejidad logarítmica en el tamaño de los datos, lo que sugiere una posible ventaja exponencial frente a los métodos clásicos.

Otro algoritmo fundamental es HHL, que resuelve sistemas de ecuaciones lineales codificando la solución en un estado cuántico. Aunque su complejidad también es favorable, el paper enfatiza sus limitaciones: la necesidad de matrices bien condicionadas, la dificultad de preparar el estado inicial y el hecho de que la solución no se obtiene explícitamente, sino como un estado cuántico.

Además, se discuten métodos de optimización como *qBLAS-based optimization*, donde problemas de machine learning se reformulan como sistemas lineales. También se mencionan enfoques variacionales y algoritmos como QAOA, que buscan resolver problemas de optimización de manera iterativa en dispositivos cuánticos actuales.

Un punto crucial del artículo es la discusión de los problemas de entrada y salida. Cargar datos clásicos en un sistema cuántico puede ser extremadamente costoso, y extraer resultados también requiere múltiples mediciones. Estos factores pueden eliminar cualquier ventaja teórica del algoritmo, lo que representa uno de los mayores desafíos del QML.

Finalmente, el paper destaca que una de las aplicaciones más prometedoras es el uso de QML para datos cuánticos, donde estos problemas desaparecen. También se menciona el uso de machine learning para mejorar el control de sistemas cuánticos, lo que muestra una relación bidireccional entre ambas áreas.

Como reflexión, este artículo deja una idea muy clara: el potencial del QML depende fuertemente de condiciones ideales que aún no se cumplen en la práctica. Sin embargo, también muestra que el campo tiene un enorme potencial, especialmente cuando se trabaja directamente con sistemas cuánticos. En ese sentido, más que una herramienta inmediata, el QML parece ser una apuesta a futuro que podría redefinir tanto la computación como el aprendizaje automático. A mí en lo personal me ha servido mucho esta actividad (principalmente el prepararme para la expo) pues este tema es la base de lo que realizo en mi tesis de licenciatura y muy probablemente utilice referencias ambos artículos para complementar gran parte de la información de la sección de QML.